

李志强, 田有, 赵鹏飞等. 2021. 基于深度学习的接收函数自动挑选方法. 地球物理学报, 64(5):1632-1642, doi:10.6038/cjg202100378.

Li Z Q, Tian Y, Zhao P F, et al. 2021. Receiver functions auto-picking method on the basis of deep learning. *Chinese J. Geophys.* (in Chinese), 64(5):1632-1642, doi:10.6038/cjg202100378.

基于深度学习的接收函数自动挑选方法

李志强¹, 田有^{1,2,3*}, 赵鹏飞^{1,2}, 刘财^{1,2}, 李洪丽^{1,2}

1 吉林大学地球探测科学与技术学院, 长春 130026

2 吉林大学地球信息探测仪器教育部重点实验室, 长春 130026

3 长白山火山综合地球物理教育部野外科学观测研究站, 长春 130026

摘要 接收函数作为地震学研究中的重要方法之一, 在间断面成像、S 波速度结构反演方面应用广泛. 然而, 接收函数方法需要耗费大量的人工成本挑选可用的数据, 这不利于我们快速准确地获得地下结构, 因此发展快速准确的数据自动处理方法具有十分重要的意义. 本文针对这一问题, 提出利用深度学习自动挑选接收函数, 并使用中国地震局的牡丹江地震台(MDJ)和北京地震台(BJT)于 2000 年至 2019 年记录的波形数据提取的接收函数进行试验. 结果表明, 应用深度学习自动挑选接收函数是可行的, 使用自动挑选的接收函数对台站下方地壳结构进行估计, 结果与使用人工挑选的接收函数估计的结果具有较高的一致性. 通过使用不同样本比例的训练集和测试集进行分析, 本文提出的方法具有对训练集的数据量要求较低、利用率高、适合多台数据联合训练等特点. 该方法在建立台网接收函数自动挑选模型字典、区域接收函数自动挑选模型等方面具有巨大应用潜力.

关键词 深度学习; 接收函数; $H-k$ 叠加; 各向异性

doi:10.6038/cjg202100378

中图分类号 P315

收稿日期 2020-10-09, 2020-12-08 收修定稿

Receiver functions auto-picking method on the basis of deep learning

LI ZhiQiang¹, TIAN You^{1,2,3*}, ZHAO PengFei^{1,2}, LIU Cai^{1,2}, LI HongLi^{1,2}

1 College of Geo-exploration Science and Technology, Jilin University, Changchun 130026, China

2 Key Laboratory of Geophysical Exploration Equipment, Ministry of Education, Jilin University, Changchun 130026, China

3 Changbai Volcano Geophysical Observatory, Ministry of Education, Changchun 130026, China

Abstract As a commonly used seismic tool, receiver functions analysis plays significant roles in detecting discontinuous interface of the earth and S wave velocity inversion. However, picking receiver functions needs lots of manpower, which is a barrier for us to obtain the underground structure fast and precisely. In this condition, a fast and efficient method is urgently needed. In this work, we establish a deep learning network to auto-pick receiver functions. Receiver functions from 2000 to 2019 calculated from MDJ and BJT stations, belonging to China Earthquake Administration, are used to test our method, and the results show that the deep learning method is effective in receiver functions auto-picking. Those auto-picked data are used to estimate the crustal structure beneath the two stations. It shows a high degree of consistency compared with manual picked data. Several groups' experiments are carried out to analyze the influence of

基金项目 国家自然科学基金(41874049)、国家重点研发计划“深地资源勘查开采”项目(2017YFC0601301)与中央高校基本科研业务费项目联合资助.

第一作者简介 李志强, 男, 1996 年生, 硕士研究生, 从事接收函数研究工作. E-mail: zqli18@mails.jlu.edu.cn

* 通讯作者 田有, 男, 1979 年生, 教授, 从事地球内部结构成像研究工作. E-mail: tianyou@jlu.edu.cn

testing data size, helping us make a conclusion that our method has following advantages as less dependence for size of training set, fully mining useful seismic data and suitable for joint analysis of multi-stations. Once accuracy receiver functions auto-picking models of the seismic stations are built, it will have an enormous potential for auto-picking receiver functions in the future.

Keywords Deep learning; Receiver functions; $H-k$ stacking; Anisotropy

0 引言

海量地震数据的取得为人类认识地球带来了可能. 随着计算机硬件水平的快速提高, 应用计算机自动处理地震数据, 替代繁复机械的人工流程进行诸如震相识别、走时初至拾取、接收函数挑选、余震序列识别等工作是十分必要的. 传统的自动处理算法包括: 利用短长时平均比值的 STA/LTA 方法 (Allen, 1978; Withers et al., 1998) 进行震相识别, 利用“V”字分形曲线首个突变点拾取震相的分形分维法 (Sleeman and Van Eck, 1999; 赵大鹏等, 2013), 利用不同波震相信噪比挑选接收函数等 (Gao and Liu, 2014). 然而这些方法在处理精度和效率上各有局限, 仍需发展更加全面快捷的计算机自动处理方案.

自 Hinton 等 (2006) 的开创性工作以来, 深度学习蓬勃发展, 并在地震大数据的自动处理和油气藏研究中崭露头角. 付超等 (2018) 将卷积神经网络与支持向量机方法结合, 提出了多波地震油气储层分布预测的深度学习方法; 林年添等 (2018) 利用卷积神经网络预测地震油气储层; 赵明等 (2019a, b) 利用 U 型卷积神经网络进行 Pg 和 Sg 震相的识别和到时提取, 常规的 U 网络用来处理二维或者三维数据, 将其降维设计即可用来处理一维地震波形; 蒋一然和宁杰远 (2019) 利用支持向量机设计了地震信号探测器 SSD 和震相分离器 SPS 用来震相的分类和到时的拾取; 李健等 (2020) 利用美国南加州地震台网的 200 万条震相和噪声数据训练的卷积神经网络模型应用到实际地震数据的震相拾取当中取得了较好的效果; 地震紧急预警中的应用可见胡安冬和张海明 (2020) 的文章; 奚先和黄江清 (2020) 应用卷积神经网络进行地震剖面中散射体的定位和成像. 许多优秀的模型和程序包也被分享到开源社区当中供研究人员学习和使用, 如用于识别震相的 PhasePapy (Chen and Holland, 2016); 泛化能力较强的 ConvNet (Ross et al., 2018); 断层自动识别软件 FaultSeg3D (Wu et al., 2018); 用以地震走时初至拾取的

PickNet 等 (Wang et al., 2019; Geng and Wang, 2020).

深度学习在地震震相识别、走时拾取、断层识别等领域的发展和应用较快并取得了较好的成果, 但是在接收函数研究中仍少有应用. 接收函数和地震波一样都是一种时间序列, 常规处理中同样需要人工重复机械的挑选. 将应用于地震波中的深度学习方法迁移到接收函数挑选是可行且必要的. 接收函数在特定的区域具有较为一致的形态, 通常会根据 P 波、Ps 转换波以及 PpSs + PsPs 的震相是否清晰一致选择保留或舍弃, 这实质上构成了一种二分类问题, 且特征数量较少, 使得接收函数的挑选训练不需要巨量的数据, 也不需要过于复杂的网络即可达到令人满意的准确度. 这一前提保证了即使是流动台站或其他观测周期较短的台站, 也可以通过手动挑选少量接收函数来构建训练集, 使用训练后的模型对剩余数据以及小于 5.5 级的小震数据进行挑选, 以实现节省人工、提高整体接收函数质量的目的. 而对于永久台站, 训练一次模型就可以供以后本台所有数据的挑选使用, 若能建立起区域台网模型字典, 将具有较高的应用价值.

卷积神经网络 (Convolutional Neural Network, CNN) 是深度学习中具有代表性的一种, 其人工神经元可以使邻近的神经元之间互相产生影响. 常规的卷积神经网络包括卷积层 (Convolutional Neural Layers)、池化层 (Max Pooling) 和全连接层 (Fully Connected Neural Layers, FCN). 相比其他深度学习结构, CNN 在图像识别和语音识别方面具有一定优势, 且已经有很成熟的开源框架, 可以较容易的搭建出面向接收函数挑选问题的网络结构. 据此本文设计了一种 CNN 网络来挑选接收函数, 并采用实际观测数据来验证方法的可行性.

1 数据和方法

1.1 接收函数提取

本文所使用的数据取自中国地震局的两台永久台站, 黑龙江省牡丹江地震台 (MDJ) 和北京地震台

(BJT). 两个地震台都具有较长的地震观测周期, 能够提取大量接收函数应用模型训练. 两个台站使用的数据下载自美国地震学研究联合会 (Incorporated Research Institutions for Seismology, IRIS) 网站 (<http://ds.iris.edu>), 选取 2000 年到 2019 年的震级大于 5.1 级、震中距 $30^{\circ} \sim 90^{\circ}$ 的三分量事件波形数据. 根据 P 波理论到时截取波形 P 波前 20 s, 后 60 s, 之后进行去均值、尖刺、倾斜操作, 并对数据进行 0.05~10 Hz 的带通滤波, 并由 ZNE(垂、北、西) 坐标系旋转至 ZRT(垂、径向、切向) 坐标系. 采用时间域迭代反褶积方法 (Ligorria and Ammon, 1999) 计算接收函数, 高斯因子设置为 2.5.

对得到的 MDJ 台 15329 条接收函数、BJT 台 14524 条接收函数进行人工挑选和标签的制作. 接收函数保存为 sac 文件格式, 截取 P 波前 5 s, 后 25 s 共 30 s 的数据, 采样率 20 Hz, 保留的接收函数头文件中 t1 参数设置为 1, 舍弃的 t1 参数设置为 0.

1.2 神经网络搭建

本研究搭建的神经网络基于 LeNet-5 (LeCun et al., 1998, 2015) 手写数字识别模型. 如图 1 所示, 整个网络有 7 层, 前 4 层为卷积层和池化层交替, 输入为一维序列, 对其进行卷积, 使用大小为 1×5 的一维卷积核, 滑动步长 1, 深度 16, 选用 ReLU 函数

作为激活函数, 此时神经元数量为 $600 \times 16 = 9600$ 个. 后接一层池化层, 设定一个 1×2 的滑动窗口, 滑动步长为 2, 选取其中的最大值输出到下一层, 神经元数量减少到 4800 个. 重复进行一次卷积、池化操作, 神经元数目进一步减少到 2400 个. 后 3 层为全连接层, 大小设置为 256、60 和 2, 采用 Dropout (Srivastava et al., 2014) 方法, 按照 0.5 的概率舍弃部分神经元以防止训练过程中的过拟合情况发生.

对于接收函数挑选, 只有两种结果: 保留、舍弃. 这本质上构成了一种二分类问题, 我们可以对输出结果进行 One-hot 编码, 保留编码为 $[1, 0]$, 舍弃编码为 $[0, 1]$. 基于 TensorFlow (ver: 1.15.0, <https://www.tensorflow.org>) 软件平台和 Python (ver: 3.7.3) 语言环境搭建深度学习模型, 每次输入 100 个带标签的接收函数作为一个训练批次, 采用加入 L2 正则化的交叉熵损失函数作为 Loss 函数, 利用 Adam 优化算法 (Kingma and Ba, 2014) 训练网络参数, 最大训练次数设置为 30000 次. 训练采用一块 NVIDIA Quadro P5200 显卡, 训练耗时 140 s 左右.

1.3 网络训练

接收函数形态受地形影响较大, 不同的地壳结构获得的接收函数具有一定的差异. 例如高原地区

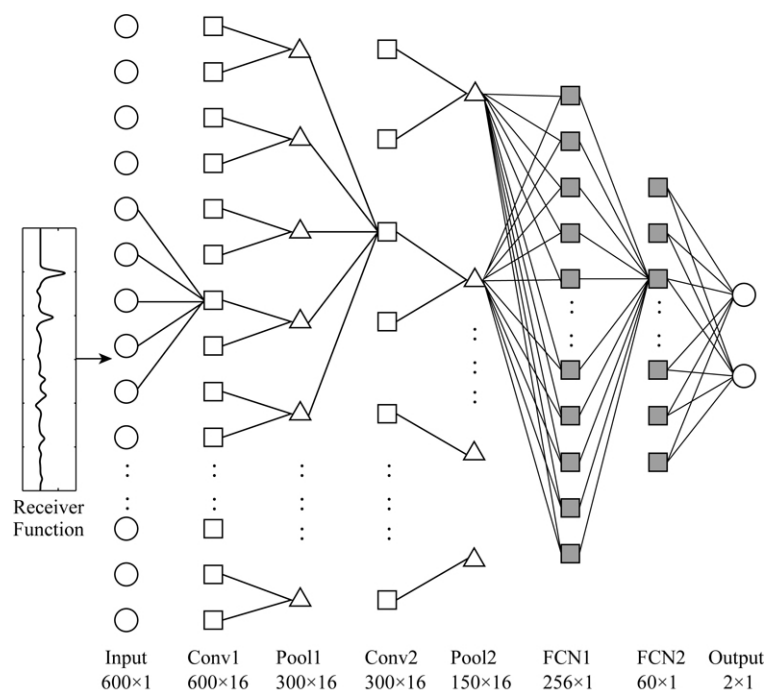


图 1 深度学习自动挑选接收函数网络结构

每个几何图形代表网络中的一个节点. 网络下方列出了每一层的类型以及对应的节点数、通道数.

Fig. 1 Architecture of the deep learning network used for receiver functions auto-picking

Each shape corresponds to a node in the net. The characteristics of each layer, number of nodes and channels are also listed at the bottom.

的接收函数由于地壳过于复杂,各个震相会难以辨别(Shi et al., 2015),而沉积盆地地区的接收函数直达 P 波、转换波和多次反射波会被沉积层混响所覆盖(朱洪翔等, 2018). 因此采用单台计算出的接收函数,每台训练一个属于自己的模型,将在一定程度上保证训练和测试样本的相关性,从而降低学习难度,提高识别准确率.

首先要构建训练集和测试集,我们将两个台站的所有数据进行人工挑选,并按照上文所述对 t_1 参数进行标记. 训练集使用 2000 年到 2016 年的数据,测试集使用 2017 年到 2019 年的数据. MDJ 训练集 13531 个接收函数中带有保留标签的有 1969 个,占比 14.5%;测试集 1798 个接收函数中带有保留标签的有 283 个,占比 15.7%;BJT 训练集 12730 个接收函数中带有保留标签的有 3285 个,占比 25.8%;测试集 1812 个接收函数中带有保留标签的有 496 个,占比 27.3%.

两个台站的网络结构从 8000 次训练左右开始收敛稳定,如图 2 所示的 Loss 变化曲线. 二分类问题常用的评价标准包括准确率和召回率,准确率表示正负样本被正确分类的比例,召回率表示在实际为正的样本中被预测为正样本的比例,二者计算公式如公式(1)、(2)所示:

$$ACC = \frac{N_{TP} + N_{TN}}{N_{TP} + N_{TN} + N_{FP} + N_{FN}}, \quad (1)$$

$$TPR = \frac{N_{TP}}{N_{TP} + N_{FN}}, \quad (2)$$

其中 ACC 表示准确率,TPR 表示召回率, N_{TP} 表示正类样本被正确分类的数目, N_{TN} 表示负类样本被正确分类的数目, N_{FP} 表示负类样本被分为正类的数目, N_{FN} 表示正类样本被分为负类的数目.

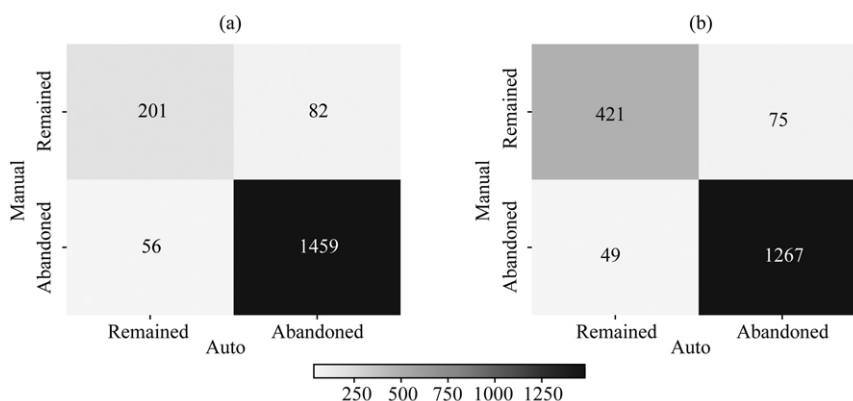


图 3 测试集混淆矩阵热力图

(a) MDJ 台; (b) BJT 台.

Fig. 3 Heatmaps showing confusion matrix of testing datasets

(a) MDJ station; (b) BJT station.

使用最终训练模型测试两个台站的测试集, MDJ 台的准确率达到 92.3%,召回率达到 71.0%,BJT 台的准确率达到 93.1%,召回率达到 84.8%. 两台测试集的挑选情况以混淆矩阵热力图的形式在图 3 给出. MDJ 台召回率较 BJT 台低,经分析是 MDJ 台测试集正类样本所占比例较低所致. 两台站原始接收函数见图 4(a,e),自动挑选结果见图 4(b,f),人工挑选结果见图 4(c,g),可以看出自动挑选结果与人工挑选结果具有较高的相似性. 由于标签的制作具有比较大的主观因素,因此存在将质量稍差




图 2 Loss 函数随训练次数变化曲线

(a) MDJ 台; (b) BJT 台.

Fig. 2 Variation curve of loss function during the training processing

(a) MDJ station; (b) BJT station.

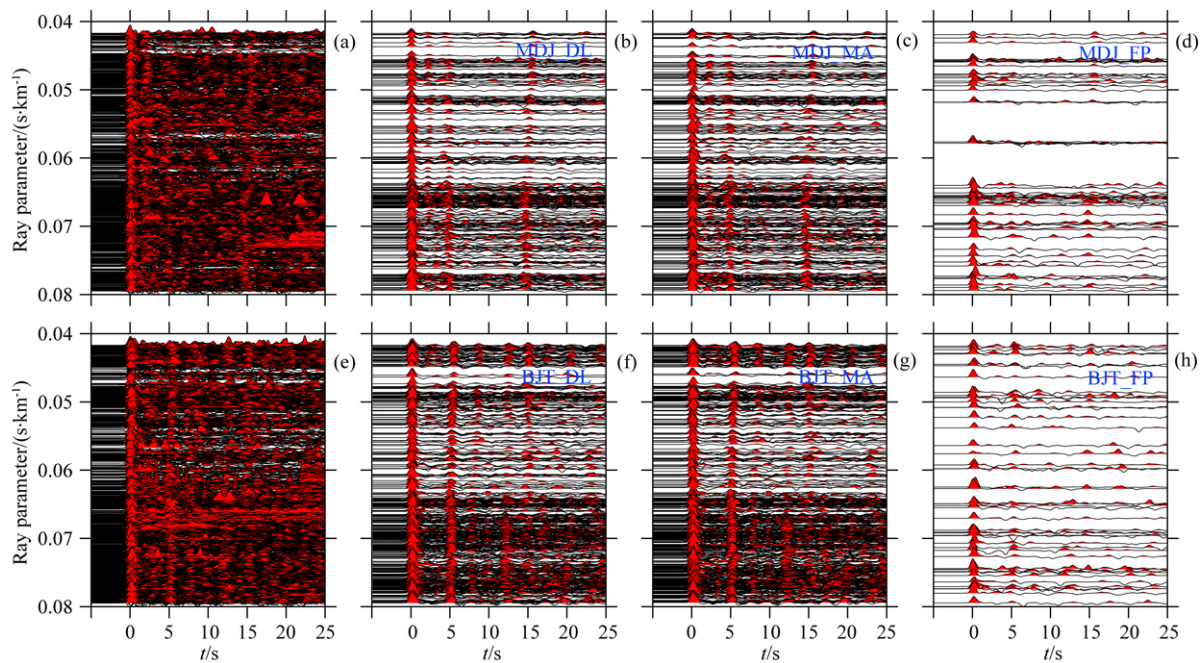


图4 人工挑选与深度学习自动挑选的接收函数结果对比

(a) MDJ 台原始未挑选的接收函数; (b) MDJ 台自动挑选结果(MDJ_DL); (c) MDJ 台手工挑选结果(MDJ_MA); (d) MDJ 台自动挑选而未被人工挑选的接收函数(MDJ_FP); (e—h)与(a—d)相同,表示 BJT 台对应结果。

Fig. 4 Contrast of manual picking receiver functions and deep learning auto-picking receiver functions

(a) All receiver functions in testing dataset of MDJ station; (b) Receiver functions of MDJ station after deep learning auto-picking (MDJ_DL); (c) Receiver functions of MDJ station after manual picking(MDJ_MA); (d) Receiver functions of MDJ station remained by deep learning but not manually remained; (e—h) are same as (a—d) but for BJT station.

的接收函数标记为保留,将质量较好的接收函数标记为舍弃,甚至会有某些接收函数在挑选时保留亦或舍弃都可以的情况. 根据大多数正确分类接收函数规律训练出的模型,在测试时也会受到人为因素导致的错误标签的影响,这些错误分类的接收函数具有一定的“模糊性”,即使人工挑选也可留可弃,对后续处理影响较小. 自动挑选而未被人工挑选的接收函数见图 4(d,h),可以看到这些接收函数分布没有明显规律,同时按人工挑选经验,这些接收函数也是可以保留的。

2 地壳结构与各向异性估计

为验证自动挑选的接收函数在实际处理分析中的有效性,我们分别使用人工挑选的接收函数和自动挑选的接收函数对两个台站下方的地壳厚度、波速比以及方位各向异性进行计算,并对对比结果进行分析。

2.1 地壳厚度与波速比

为估计两个台站下方的地壳厚度以及波速比,我们采用接收函数处理中常用的“ $H-\kappa$ 叠加”(Zhu and Kanamori, 2000)方法. Ps 波、PpPs 波以及 PpSs

+PsPs 波相对于 P 波的时差(t_{Ps} 、 t_{PpPs} 、 $t_{PpSs+PsPs}$)可以表示为地壳厚度、地壳纵横波速度比和射线参数的函数. 将一个台站的所有接收函数按照公式(3)进行叠加,即可估计台站下方地壳厚度 H 和平均波速比 κ . 式(3)中, A_i 为第 i 个接收函数对应时差的幅值, ω_1 、 ω_2 、 ω_3 分别为三种震相叠加的权系数, MDJ 台权系数设为 0.7、0.2 和 0.1, BJT 设为 0.8、0.1 和 0.1, N 为该台站参与叠加的接收函数的数目。

$$s(H, \kappa) = \frac{1}{N} \sum_{i=1}^N \left\{ \omega_1 A_i(t_{Ps}) + \omega_2 A_i(t_{PpPs}) + \omega_3 A_i(t_{PpSs+PsPs}) \right\}. \quad (3)$$

图 5(a,d)分别为 MDJ 台和 BJT 台测试集通过深度学习算法挑选的接收函数的 $H-\kappa$ 叠加结果;图 5(b,e)分别为 MDJ 台和 BJT 台测试集通过人工挑选的接收函数 $H-\kappa$ 叠加结果;图 5(c,f)分别为 MDJ 台和 BJT 台所有人工挑选的接收函数 $H-\kappa$ 叠加结果. 图 5(a,b,c)对比可以看出不同挑选方案得到的 MDJ 台下地壳厚度和波速比分别为 35.2 km/1.83、34.9 km/1.84、34.8 km/1.84;图 5(d,e,f)对比可以看出不同挑选方案得到的 BJT 台下地壳厚度和波速比分别为 38.4 km/1.78、37.9 km/1.79、37.8 km/1.80;




图5 $H-\kappa$ 叠加获得的两台站下方地壳厚度和平均波速比

(a) MDJ 台自动挑选数据 $H-\kappa$ 叠加结果; (b) MDJ 台人工挑选数据 $H-\kappa$ 叠加结果;

(c) MDJ 台全部人工挑选数据 $H-\kappa$ 叠加结果. (d—f) 与 (a—c) 相同, 表示 BJT 台结果.

Fig. 5 Crustal thickness and average V_p/V_s beneath the two stations obtained by $H-\kappa$ stacking

(a) $H-\kappa$ stacking results using deep learning auto-picking data of MDJ station; (b) $H-\kappa$ stacking results of manual picking data of MDJ station;

(c) $H-\kappa$ stacking results of all manual picking data of MDJ station; (d—f) are same as (a—c) but for BJT station.

可以看出两个台站经深度学习挑选的接收函数 $H-\kappa$ 叠加结果和人工结果基本一致, 说明神经网络用于接收函数的自动挑选具有较好的适用性.

2.2 地壳各向异性

我们进一步使用接收函数 P_s 震相估计台站下方的地壳方位各向异性. 在单层水平地壳假设下, 接收函数 P_s 转换波与直达 P 波的到时差可以由反方位角余弦表示 (Liu and Niu, 2012; Zheng et al., 2018), 公式如下:

$$t = t_0 + \Delta t = t_0 - \frac{dt}{2} \cos[2(\Phi - \text{Baz})], \quad (4)$$

式(4)中, t 为接收函数 P_s 转换波与直达 P 波的到时差, t_0 为各向同性介质假设下的到时差, Δt 为各向异性介质产生的到时差, dt 是表征地壳各向异性强度的横波分裂后快慢横波到时差, Φ 是表征地壳各向异性快轴方向的快横波极化方向, Baz 为反方位角. 我们需要估计的即是 t_0 、 dt 、 Φ 三个参数. 在本研究中, 参数估计利用遗传算法 (Holland, 1992) 进

行,采用二进制编码,每个参数由八位二进制表示,总基因长度为 24, t_0 、 dt 、 Φ 三个参数范围分别设置为 $4 \sim 8$ s、 $0 \sim 0.8$ s、 $-90^\circ \sim 90^\circ$,所有接收函数 Ps 转换波振幅值之和作为适应度函数,用公式表示为:

$$F = \sum_{i=1}^N \text{RFA}(t), \quad (5)$$

式中 F 为适应度函数, $\text{RFA}(t)$ 表示 Ps 转换波振幅值, t 由式(4)表示. 种群设置为 50, 遗传 100 代截止,交叉概率和变异概率分别设置为 0.6 和 0.05.

接收函数预处理采用 Zheng 等(2018)提出的方法,为消除不同震中距对到时差的影响,Ps 震相经过了动校正处理. 接下来对接收函数进行叠加平均,使用平均后的接收函数估计各个参数.

图 6(a、e)分别为 MDJ 台和 BJT 台通过深度学习方法从测试集中挑选出的接收函数通过遗传算法估计 t_0 、 dt 、 Φ 三个参数的进化图;图 6(b、f)为图 6

(a、e)各向异性估计结果所对应的接收函数 Ps 波理论到时差曲线;图 6(c、g)分别为 MDJ 台和 BJT 台人工从测试集中挑选出的接收函数通过遗传算法估计 t_0 、 dt 、 Φ 三个参数的进化图;图 6(d、h)为图 6(c、g)各向异性估计结果所对应的接收函数 Ps 波理论到时差曲线. 将两台各向异性对比结果绘制在图 7 所示的地形图上,可以看出人工挑选的接收函数和深度学习挑选的接收函数估计出的各向异性结果比较一致.

3 讨论

3.1 训练集数目的影响

前文我们使用了 2000—2016 年 16 年的接收函数作为训练集,2017—2019 两年的接收函数作为测试集,测试集与训练集之比接近 1:7,最终模型自动挑选接收函数可以达到较好的精度. 然而,对于布设

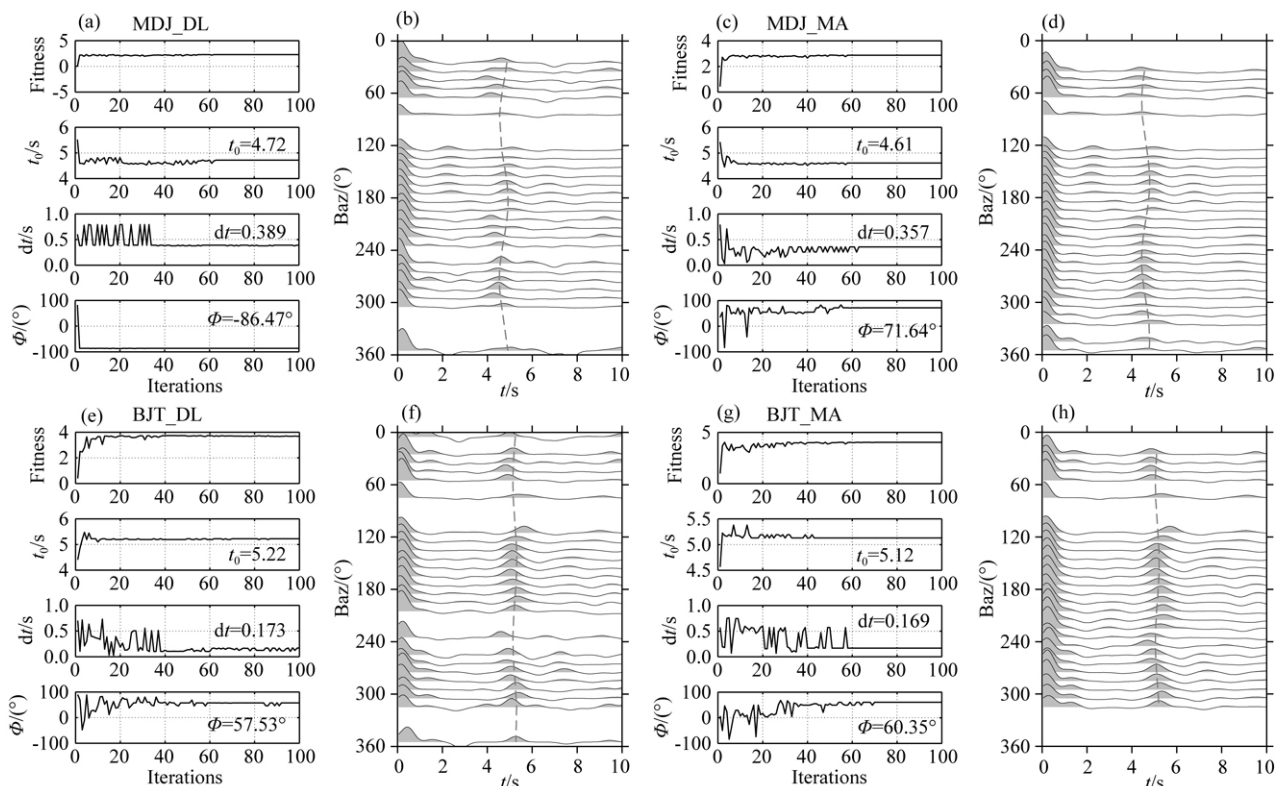


图 6 两站下方地壳方位各向异性结构

(a) MDJ 台自动挑选出的接收函数,采用遗传算法(GA)估计各向异性时的适应度函数以及各向异性参数变化;(b)与各向异性参数估计结果相对应的 Ps 波理论到时差;(c—d)与(a—b)相同,表示 MDJ 台人工挑选的接收函数计算结果;(e—h)与(a—d)相同,表示 BJT 台自动、人工挑选出的接收函数估计各向异性结果.

Fig. 6 Crustal azimuthal anisotropy structure beneath the two stations

(a) The variation of fitness, anisotropic parameters in genetic algorithm (GA) using deep learning auto-picking receiver functions of MDJ station; (b) Theoretical Ps wave delay time corresponds to estimated anisotropic parameters; (c—d) are same as (a—b) but use all of manual picking receiver functions of MDJ station; (e—h) are same as (a—d) but for BJT station.




图7 台站所在位置及图6中获取的各向异性结果对比
蓝色实线为自动挑选的接收函数估计的结果,红色实线为
人工挑选的接收函数估计的结果。

Fig. 7 Locations of the two stations and the contrast
of anisotropy results obtained from Fig. 6

Blue lines represent the estimations from deep learning auto-picking receiver functions and the red lines are anisotropy results from all of manual selection receiver functions.

时间较短的流动台站或其他临时台站,无法提供大量的数据以供训练.为此我们探究了只应用较小规模的训练集是否也能达到较好的效果.我们重新划分训练集规模进行训练,剩余数据用作测试集进行试验.

表1为MDJ台不同训练集大小的训练结果,训练集规模从552条接收函数递增,最终增加到13531条.最终训练模型应用于测试集后准确率均达到了90%以上,召回率70%以上.同时我们发现,对于召回率,测试集规模过大反而导致了召回率呈下降趋势,仅用一年的数据训练的模型,准确率保证的前提下,召回率反而得到了提升.经过分析,我们发现导致这一现象的原因是对于较小规模的训练集,其正类样本所占比例较高,表1中Remained一列表示训练集中正类样本所占的比例.如此一来,小规模训练集能够获得相对更好的挑选效果,这一前提为流动台站采取此类方法提供了可能.

表1 MDJ台不同训练集规模情况下的测试集准确率和召回率

Table 1 The influence of testing data size on accuracy and recall of MDJ station

	Train (Span)	Train (Datasize)	Remained (%)	Test (Span)	Test (Datasize)	Accuracy (%)	Recall (%)
1	2000	552	24.2	2001—2019	14777	90.9	83.6
2	2000—2002	1841	18.7	2003—2019	13488	91.6	78.8
3	2000—2004	3378	16.8	2005—2019	11951	91.9	78.4
4	2000—2008	7042	14.5	2009—2019	8287	92.9	74.3
5	2000—2012	10472	13.6	2013—2019	4857	92.7	70.1
6	2000—2016	13531	14.5	2017—2019	1798	92.3	71.0

3.2 深度学习方法及在 ≤ 5.5 级地震接收函数挑选的作用

在本研究中使用了近20年时间跨度的地震数据,使得我们可以通过统计学对接收函数挑选中所使用的地震震级情况进行分析.如图8所示,MDJ和BJT台站接收到的震级范围 $M_{5.1} \sim 5.5$ 的事件占比分别为64.5%和64.7%,占比明显高于震级 $\geq M_{5.5}$ 的事件,但是从震级范围 $M_{5.1} \sim 5.5$ 的事件中人工挑选出的接收函数分别只占到该震级范围内总事件数的2.5%和7.07%,而从震级 $\geq M_{5.5}$ 的事件中挑选出的接收函数占比达到了23.21%和16.29%,意味着在人工挑选过程中,是没有必要花费大量精力挑选 $\leq M_{5.5}$ 的数据只为获取较少的数据的,这就是我们通常只选取震级大于5.5级的事件进行接收函数分析工作的原因.

由于人工挑选数据的局限性舍弃掉的小震级接收函数数据,在使用自动挑选时则可以得以保留.采

用深度学习自动挑选接收函数时,不需要担心人工成本的问题.应用训练好的模型可以快速从小于5.5级的地震事件中挑选出少量高质量的接收函数,从而提高数据的利用率.

3.3 多台联合训练

对于永久台站,可以选取每个台站几年的数据进行训练,将所有模型建立一个台网字典供以后直接使用.但是对于大量的流动台站,其观测周期较短,单台接收函数训练结果泛化能力有较大的局限性,此时采用多台数据联合训练,建立一个公共的模型是有必要的.

受台站数目限制,本次研究仅对上文使用的两个台站进行联合训练测试.我们将MDJ台和BJT台的训练集合并,测试集合并,同样经历30000次训练,最终得到的模型应用于测试集准确性达到了92.5%,召回率达到81.3%,再次使用 $H-\kappa$ 叠加方法对台站下方的地壳厚度和各向异性进行估计,如图9所示,得到MDJ台下地壳厚度为35.2 km,平





图 8 不同震级范围计算的接收函数统计分析

(a) MDJ 台; (b) BJT 台. 角标 Y 代表保留, N 代表舍弃.

Fig. 8 Statistical analysis of receiver functions in different magnitude range

(a) MDJ station; (b) BJT station. The subscript "Y" denotes being remained, "N" denotes being abandoned.

图 9 双台联合训练自动挑选的接收函数 $H-\kappa$ 叠加结果

(a) MDJ 台; (b) BJT 台.

Fig. 9 $H-\kappa$ stacking results of two stations using joint training sets

(a) MDJ station; (b) BJT station.

均波速比为 1.83; BJT 台下地壳厚度为 37.9 km, 平均波速比为 1.79. 两台最终计算结果与人工挑选的接收函数计算结果或单台自动挑选的接收函数计算结果均较为一致, 表明建立区域多台联合接收函数挑选模型具有一定可行性. 更多台站准确分析结果需要后续工作继续跟进.

4 结论

本文发展了一种基于深度学习的接收函数自动挑选方法, 参照 LeNet5 模型构建 CNN 神经网络, 并使用中国地震局 MDJ 台和 BJT 台的事件波形提取接收函数, 构建训练集和测试集进行验证. 实际数据应用结果表明, 利用本文提出的深度学习自动挑

选接收函数方法具有较高的准确率. 对于自动挑选的接收函数, 我们使用 $H-\kappa$ 叠加方法和 P_s 震相到时差计算了两个台站下方的地壳厚度、平均波速比以及地壳方位各向异性等地壳参数, 得出以下结论:

(1) 本文提出的深度学习方法挑选的接收函数和人工挑选的接收函数估计的地壳厚度、平均波速比和方位各向异性结果基本一致, 证明了本文提出的自动挑选方法的可行性.

(2) 本研究提出的方法在构建训练集过程中, 对训练集数据数量有较低的依赖, 试验中尽管只应用几百条接收函数训练, 应用最终模型挑选上万条接收函数也可达到 90% 以上准确率和 80% 以上的召回率.

(3) 本研究提出的自动挑选方法可以应用于

5.1~5.4 级远震,有效地提高了观测数据的利用率,为后续的分析、研究提供更好的约束。

(4)对于流动台站,同时使用多个台站的数据构建训练集以提高泛化能力,最终模型在测试集的表现也让人满意。

致谢 感谢 IRIS 网站提供的地震数据(<http://ds.iris.edu>),感谢吉林大学朱洪翔博士提出的宝贵意见,感谢审稿专家给出的修改意见。

References

- Allen R V. 1978. Automatic earthquake recognition and timing from single traces. *Bulletin of the Seismological Society of America*, 68(5): 1521-1532.
- Chen C, Holland A A. 2016. PhasePAPy: a robust pure python package for automatic identification of seismic phases. *Seismological Research Letters*, 87(6): 1384-1396.
- Fu C, Lin N T, Zhang D, et al. 2018. Prediction of reservoirs using multi-component seismic data and the deep learning method. *Chinese Journal of Geophysics* (in Chinese), 61(1): 293-303, doi: 10.6038/cjg2018L0193.
- Gao S S, Liu K H. 2014. Mantle transition zone discontinuities beneath the contiguous United States. *Journal of Geophysical Research: Solid Earth*, 119(8): 6452-6468.
- Geng Z, Wang Y F. 2020. Automated design of a convolutional neural network with multi-scale filters for cost-efficient seismic data classification. *Nature Communications*, 11: 3311.
- Hinton G E, Osindero S, Teh Y W. 2006. A fast learning algorithm for deep belief nets. *Neural Computation*, 18(7): 1527-1554.
- Holland J H. 1992. *Adaptation in Natural and Artificial Systems*. Ann Arbor: University of Michigan Press. 126-137.
- Hu A D, Zhang H M. 2020. Application of machine learning to magnitude estimation in earthquake emergency prediction system. *Chinese Journal of Geophysics* (in Chinese), 63(7): 2617-2626, doi: 10.6038/cjg2020N0070.
- Jiang Y R, Ning J Y. 2019. Automatic detection of seismic body-wave phases and determination of their arrival times based on support vector machine. *Chinese Journal of Geophysics* (in Chinese), 62(1): 361-373, doi: 10.6038/cjg2019M0442.
- Kingma D P, Ba J. 2014. Adam: a method for stochastic optimization. *Computer Science*, arXiv:1412.6980.
- Lecun Y, Bottou L, Bengio Y, et al. 1998. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11): 2278-2324.
- LeCun Y, Bengio Y, Hinton G. 2015. Deep learning. *Nature*, 521(7553): 436-444.
- Li J, Wang X M, Zhang Y H, et al. 2020. Research on the seismic phase picking method based on the deep convolution neural network. *Chinese Journal of Geophysics* (in Chinese), 63(4): 1591-1606, doi: 10.6038/cjg2020N0057.
- Ligorria J P, Ammon C J. 1999. Iterative deconvolution and receiver-function estimation. *Bulletin of the Seismological Society of America*, 89(5): 1395-1400.
- Lin N T, Zhang D, Zhang K, et al. 2018. Predicting distribution of hydrocarbon reservoirs with seismic data based on learning of the small-sample convolution neural network. *Chinese Journal of Geophysics* (in Chinese), 61(10): 4110-4125, doi: 10.6038/cjg2018J0775.
- Liu H F, Niu F L. 2012. Estimating crustal seismic anisotropy with a joint analysis of radial and transverse receiver function data. *Geophysical Journal International*, 188(1): 144-164.
- Ross Z E, Meier M A, Hauksson E, et al. 2018. Generalized seismic phase detection with deep learning. *Bulletin of the Seismological Society of America*, 108(5A): 2894-2901.
- Shi D N, Wu Z H, Klemperer S, et al. 2015. Receiver function imaging of crustal suture, steep subduction, and mantle wedge in the eastern India-Tibet continental collision zone. *Earth and Planetary Science Letters*, 414: 6-15.
- Sleeman R, Van Eck T. 1999. Robust automatic P-phase picking: an on-line implementation in the analysis of broadband seismogram recordings. *Physics of the Earth and Planetary Interiors*, 113(1-4): 265-275.
- Srivastava N, Hinton G, Krizhevsky A, et al. 2014. Dropout: A simple way to prevent neural networks from overfitting. *The Journal of Machine Learning Research*, 15(1): 1929-1958.
- Wang J, Xiao Z W, Liu C, et al. 2019. Deep learning for picking seismic arrival times. *Journal of Geophysical Research: Solid Earth*, 124(7): 6612-6624.
- Withers M, Aster R, Young C, et al. 1998. A comparison of select trigger algorithms for automated global seismic phase and event detection. *Bulletin of the Seismological Society of America*, 88(1): 95-106.
- Wu X M, Liang L M, Shi Y Z, et al. 2019. FaultSeg3D: Using synthetic data sets to train an end-to-end convolutional neural network for 3D seismic fault segmentation. *Geophysics*, 84(3): IM35-IM45, doi: 10.1190/geo2018-0646.1.
- Xi X, Huang J Q. 2020. Location and imaging of scatterers in seismic migration profiles based on convolution neural network. *Chinese Journal of Geophysics* (in Chinese), 63(2): 687-714, doi: 10.6038/cjg2020M0490.
- Zhao D P, Liu X Q, Liu Y X, et al. 2013. Detection of regional seismic events by high order statistics method and automatic identification of direct P-wave first motion by AIC method. *Seismological and Geomagnetic Observation and Research* (in Chinese), 34(5): 61-69, doi: 10.3969/j.issn.1003-3246.2013.05/06.010.
- Zhao M, Chen S, Yuen D. 2019a. Waveform classification and seismic recognition by convolution neural network. *Chinese Journal of Geophysics* (in Chinese), 62(1): 374-382, doi: 10.6038/cjg2019M0151.
- Zhao M, Chen S, Fang L H, et al. 2019b. Earthquake phase arrival auto-picking based on U-shaped convolutional neural network. *Chinese Journal of Geophysics* (in Chinese), 62(8): 3034-

3042, doi: 10.6038/cjg2019M0495.

Zheng T, Ding Z F, Ning J Y, et al. 2018. Crustal azimuthal anisotropy beneath the southeastern Tibetan Plateau and its geodynamic implications. *Journal of Geophysical Research: Solid Earth*, 123(11): 9733-9749.

Zhu H X, Tian Y, Liu C, et al. 2018. Estimation of the crustal structure beneath the sedimentary Basin: Predictive deconvolution method to remove multiples reverberations of the receiver function. *Chinese Journal of Geophysics* (in Chinese), 61(9): 3664-3675, doi: 10.6038/cjg2018L0152.

Zhu L P, Kanamori H. 2000. Moho depth variation in southern California from teleseismic receiver functions. *Journal of Geophysical Research: Solid Earth*, 105(B2): 2969-2980.

附中文参考文献

付超, 林年添, 张栋等. 2018. 多波地震深度学习的油气储层分布预测案例. *地球物理学报*, 61(1): 293-303, doi: 10.6038/cjg2018L0193.

胡安冬, 张海明. 2020. 机器学习在地震紧急预警系统震级预估中的应用. *地球物理学报*, 63(7): 2617-2626, doi: 10.6038/cjg2020N0070.

蒋一然, 宁杰远. 2019. 基于支持向量机的地震体波震相自动识别

及到时自动拾取. *地球物理学报*, 62(1): 361-373, doi: 10.6038/cjg2019M0442.

李健, 王晓明, 张英海等. 2020. 基于深度卷积神经网络的地震震相拾取方法研究. *地球物理学报*, 63(4): 1591-1606, doi: 10.6038/cjg2020N0057.

林年添, 张栋, 张凯等. 2018. 地震油气储层的小样本卷积神经网络学习与预测. *地球物理学报*, 61(10): 4110-4125, doi: 10.6038/cjg2018J0775.

奚先, 黄江清. 2020. 基于卷积神经网络的地震偏移剖面中散射体的定位和成像. *地球物理学报*, 63(2): 687-714, doi: 10.6038/cjg2020M0490.

赵大鹏, 刘希强, 刘尧兴等. 2013. 高阶统计量及 AIC 方法在区域地震事件和直达 P 波初动识别中的应用. *地震地磁观测与研究*, 34(5): 61-69, doi: 10.3969/j.issn.1003-3246.2013.05/06.010.

赵明, 陈石, Yuen D. 2019a. 基于深度学习卷积神经网络的地震波形自动分类与识别. *地球物理学报*, 62(1): 374-382, doi: 10.6038/cjg2019M0151.

赵明, 陈石, 房立华等. 2019b. 基于 U 形卷积神经网络的震相识别与到时拾取方法研究. *地球物理学报*, 62(8): 3034-3042, doi: 10.6038/cjg2019M0495.

朱洪翔, 田有, 刘财等. 2018. 沉积盆地地区地壳结构估计——预测反褶积方法消除接收函数多次波混响. *地球物理学报*, 61(9): 3664-3675, doi: 10.6038/cjg2018L0152.

(本文编辑 何燕)